

1 Mac = 2 FLOPS

Max Pool, ReLU: $\rightarrow 0$ FLOPS

deepmm Bias = False

Memory: use torch.cuda.max-memory-allocated
3a forward pass & inference-mode()

Latency: measure between forward pass & eval()
+ inference-mode(), FP32.

Energy: measure energy forward pass & inference,
na bein GPU.

1. FLOPS (S, B)

Boxog $3 \times S \times S$

Crout 1: Conv 7×7 $S_2, 3 \rightarrow 32$, Boxog $S/2 \times S/2$

$$\text{MacS} = 32 \times 3 \times 49 \times (S/2)^2 = 1176 S^2$$

Crout 2: Max Pool 3×3 S_2 $p4 \rightarrow 0$ FLOPS.

Crout 3: Conv 5×5 $S_1, 32 \rightarrow 64$ Boxog $S/4 \times S/4$

$$\text{MacS} = 64 \times 32 \times 25 \times (S/4)^2 = 3200 S^2$$

Crout 4: Conv 3×3 $S_2, 64 \rightarrow 128$, Boxog $S/8 \times S/8$

$$\text{MacS} = 128 \times 64 \times 9 \times (S/8)^2 = 512 S^2$$

max Pool 3×3 S^2 P^4
 Conv 5×5 $S^1, 3^2 \rightarrow 64$ $B \times O \times S/4 \times S/4$
 $\dots, 12 = 3700 S^2$

Crout 5: Conv 1×1 $S^1, 128 \rightarrow 256$, ~~$B \times O \times S/8 \times S/8$~~

$$Mac_s = 256 \times 128 \times (S/8)^2 = 512 S^2$$

Crout 6: Conv 3×3 $S^2, 256 \rightarrow 256$, ~~$B \times O \times S/16 \times S/16$~~

$$Mac_s = 256 \times 256 \times 9 \times (S/16)^2 = 2304 S^2$$

Crout 7: Conv 1×1 $S^1, 256 \rightarrow 512$, ~~$B \times O \times S/16 \times S/16$~~

$$Mac_s = 512 \times 256 \times (S/16)^2 = 512 S^2$$

Crout 8: GAP, 512 channels, $S/16 \times S/16 \rightarrow 1 \times 1$

$$Mac_s = 512 \times ((S/16)^2 - 1) \approx 25^2 - 512$$

Crout 9: Linear $512 \rightarrow 256$

$$Mac_s = 131072$$

Crout 10: ReLU $\rightarrow 0$ FLOPs

Crout 11: Linear $256 \rightarrow 100$

$$Mac_s \approx 25600$$

$$\text{Total } Mac_s = 88585^2 + 156160$$

$$FLOPs = 2 Mac$$

$$FLOPs \approx (S, 13) = B \times (17716 \times S^2 + 312320)$$

ReLU $\rightarrow 0$ FLOPs

Linear 256 $\rightarrow 10$

ACS =

2. Memory

Macros

Conv 7×7 : 4704

Conv 5×5 : 51200

Conv 3×3 : ~~8000~~ 83928

Conv 1×1 : 32768

Conv 3×3 : 589824

Conv 1×1 : 131072

Conv Linear: 131328

Linear: 25700

При аккумуляции: вход $(3BS^2)$ и выход Conv7 $(8BS^2)$
Хуба одновременно $\rightarrow 11BS^2$ элементов.

$$\text{Memory}(S, B) = 4 \times (1040324 + 11 \times B \times S^2)$$

3. Bytes Moved

Какая константа: (значение входа + значение
веса + значение записи выхода) $\times 4$ байт / элемент.

B элементов.

Случай 1: Conv 7×7 $S2, 3 \rightarrow 32$

$$3BS^2 + 4704 + 8BS^2 = 11BS^2 + 4704$$

near 256 $\rightarrow$ 100

25600

S = 88

loc

(S, 13)

Layer 2: MaxPool 3×3 S2

$$8BS^2 + 2BS^2 = 10BS^2$$

Layer 3: Conv 5×5 , $32 \rightarrow 64$

$$2BS^2 + 51200 + 4BS^2 = 6BS^2 + 51200$$

Layer 4: Conv 3×3 S2, $64 \rightarrow 128$

$$4BS^2 + 73728 + 2BS^2 = 6BS^2 + 73728$$

Layer 5: Conv 1×1 , $128 \rightarrow 256$

$$2BS^2 + 32768 + 4BS^2 = 6BS^2 + 32768$$

Layer 6: Conv 3×3 S2, $256 \rightarrow 256$

$$4BS^2 + 589824 + BS^2 = 5BS^2 + 589824$$

Layer 7: Conv 1×1 , $256 \rightarrow 512$

$$BS^2 + 131072 + 2BS^2 = 3BS^2 + 131072$$

Layer 8: GAP

$$2BS^2 + 512B$$

Layer 9: Linear $512 \rightarrow 256$

$$768B + 131328$$

Layer 11: Linear $256 \rightarrow 100$

$$356B + 25700$$

256 $\rightarrow$ 100
6 B + 25700

B $\times$ (17716 $\times$ S² + 312320)

Сумма:

$$S^2: 11 + 20 + 6 + 6 + 6 + 5 + 3 + 2 = 49 \rightarrow 491352$$

$$B: 512 + 768 + 356 = 1636 \rightarrow 163613$$

$$\text{const: } 1040324$$

$$\text{Bytes Moved } (S, B) = 4 \times (49 \times B \times S^2 + 1636 \times B + 1040324)$$

4. Latency (S, B, @)

- Макс. нагрузка по FLOPs и Bytes Moved
- @₀ постоянные расходы (запуск ядра, синхронизация)
- @₁ время на 1 FLOP (обратно пропорционально FLOP/s)
- @₂ : время на 1 байт (обратно пропорционально пропускной способности)
- @ выбирается на конкретном GPU

$$\text{Latency } (S, B, @) = @_0 + @_1 \times \text{FLOPs}(S, B) + @_2 \times \text{Bytes Moved}$$

312 3207

5. Energy (S, B, Θ_e)

Energy = magnitude $\times$ latency

А Линейное количество FLOPS и Bytes Moved

Θ_{e0} : энергия расчета

Θ_{e1} : энергия на 1 FLOP.

Θ_{e2} : энергия на 1 байт.

Θ_e комбинированное количество GPU.

Energy $(S, B, \Theta_e) = \Theta_{e0} + \Theta_{e1} \times \text{FLOPS}(S, B)$

$+ \Theta_{e2} \times \text{Bytes Moved}(S, B)$